

Comparación de Modelos de Aprendizaje de Máquina en la Predicción de Ingresos Cinematográficos

Brahiam Acosta Bedoya, Kevin Estrada Del Valle, Juan Andrés Rivera Arango

Abstract—Este trabajo aborda la predicción del retorno relativo de inversión en taquilla cinematográfica mediante técnicas de aprendizaje de máquina, usando exclusivamente metadatos disponibles antes del estreno de cada película. A partir de *The Movies Dataset*, que contiene información histórica de 45 466 títulos, se construye un conjunto de trabajo de 4 721 películas con presupuesto e ingresos reportados. El problema se formula como regresión supervisada sobre $y = \log(\text{revenue}/\text{budget})$, transformación que normaliza la heterogeneidad temporal y reduce la asimetría de la variable objetivo. Las métricas de evaluación se reportan en escala original de ingresos (USD) mediante la transformación inversa.

Index Terms—Aprendizaje de máquina, regresión supervisada, predicción de ingresos, taquilla cinematográfica, análisis de datos.

I. INTRODUCCIÓN

La industria cinematográfica es uno de los mercados de entretenimiento más grandes del mundo, con ingresos globales en taquilla que superaron los 42 mil millones de dólares antes de la pandemia [1]. En este entorno, el éxito comercial de una película es difícil de anticipar: títulos con presupuestos millonarios han fracasado en taquilla, mientras que producciones modestas han superado todas las expectativas. Esta incertidumbre representa un problema real de toma de decisiones para productoras, distribuidoras e inversionistas.

Históricamente, estas decisiones han dependido del juicio experto y de comparaciones informales con títulos similares. Sin embargo, la disponibilidad de bases de datos estructuradas con metadatos de miles de películas abre la posibilidad de construir modelos cuantitativos que aprendan patrones a partir de los datos. Aquí es donde el aprendizaje de máquina ofrece una contribución concreta: a diferencia de los modelos estadísticos clásicos, los algoritmos de ML pueden capturar relaciones no lineales entre variables heterogéneas —numéricas, categóricas y estructuradas— sin requerir supuestos fuertes sobre la forma de la distribución subyacente.

Este trabajo propone aplicar técnicas de regresión supervisada para estimar el retorno relativo de inversión de una película antes de su estreno, usando únicamente información disponible en esa etapa. Se comparan múltiples modelos —desde regresión lineal hasta ensambles de árboles y redes neuronales— con el objetivo de identificar cuál captura mejor la relación entre los metadatos disponibles y el desempeño comercial.

II. DESCRIPCIÓN DEL PROBLEMA

Contexto

Estimar el retorno relativo de inversión de una película antes de su estreno es un problema de predicción con alto valor práctico. Las decisiones de inversión en la industria cinematográfica —presupuesto de marketing, número de salas, ventana de lanzamiento— se toman semanas o meses antes del estreno, cuando la única información disponible son los metadatos del proyecto: presupuesto de producción, género, idioma, fecha de lanzamiento, entre otros.

Construir un modelo que relacione estas características con el retorno esperado permite cuantificar la incertidumbre y apoyar decisiones basadas en evidencia. El problema es adecuado para un enfoque de ML porque involucra múltiples variables de distinto tipo, relaciones potencialmente no lineales entre ellas, y un volumen de datos suficiente para entrenar y validar modelos de forma robusta.

Base de datos

Se emplea *The Movies Dataset* [2], construido a partir de TMDb (*The Movie Database*) y GroupLens. El archivo principal, `movies_metadata.csv`, contiene 45 466 registros y 24 variables, complementado con `credits.csv` (45 476 filas) y `keywords.csv` (46 419 filas). Tras excluir filas con IDs malformados, eliminar duplicados, y filtrar los registros con `budget=0` o `revenue=0` —que representan datos no reportados y no ausencias reales— y restringir el período a 1960–2017, se aplican dos restricciones de dominio: se excluyen películas con presupuesto inferior a \$1 000 000 (330 registros, 6.3 %) y aquellas con ratio `revenue/budget` fuera del rango $[0.01, 30]$ (146 registros, 2.8 %), correspondientes a fenómenos virales cuyo éxito depende de variables no presentes en el dataset. El conjunto de trabajo final queda en **4 721 películas**. Las tablas I, II, III y IV describen las variables disponibles.

Calidad de datos y preprocesamiento

La variable `runtime` presenta 263 nulos (0.58 %), imputados con la mediana; las variables `status` y `original_language` tienen menos del 0.2 % de nulos, imputados con la categoría *Desconocido*. Las variables `vote_count`, `vote_average`, `popularity` y `top_actor_hist_avg` se excluyen del conjunto de predictores: las dos primeras requieren votos de usuarios que ya vieron la película; `popularity` corresponde al score actual de TMDb, no al valor pre-estreno; y `top_actor_hist_avg` se descarta por ser una señal inestable entre épocas, ya que

Table I
VARIABLES NUMÉRICAS PRINCIPALES

Variable	Tipo	Descripción
budget	Numérica continua	Presupuesto de producción en USD. Incluido como predictor por ser información conocida pre-estreno.
revenue	Numérica continua	Ingresos en taquilla en USD. Usada únicamente para construir el target; no se incluye como predictor.
runtime	Numérica continua	Duración de la película en minutos.
cast_size	Numérica entera	Número de actores en el reparto (de credits.csv).
crew_size	Numérica entera	Número de integrantes del equipo de producción (de credits.csv).
keywords_count	Numérica entera	Número de palabras clave asociadas a la trama (de keywords.csv).
collection_size	Numérica entera	Número de películas de la colección/franquicia a la que pertenece el título.

Table II
VARIABLES CATEGÓRICAS, TEMPORALES Y BINARIAS

Variable	Tipo	Descripción
release_date	Fecha	Se descompone en mes, año y día de la semana.
original_language	Categórica nominal	Idioma original; idiomas con menos de 20 apariciones se agrupan en <i>otros</i> .
status	Categórica nominal	Estado de producción (Released, Rumored, etc.).
adult	Binaria	Indicador de contenido para adultos (0/1).
kw_is_sequel	Binaria	La película es una secuela (de keywords.csv).
kw_is_based_book	Binaria	Basada en un libro (de keywords.csv).
kw_is_remake	Binaria	Es un remake (de keywords.csv).
kw_is_superhero	Binaria	Pertenece al género de superhéroes (de keywords.csv).
kw_independent_film	Binaria	Producción independiente (de keywords.csv).

el historial de un actor en un período no es necesariamente representativo en períodos posteriores.

En cuanto a la codificación: **genres**,

Table III
VARIABLES ESPECIALES (JSON, TEXTO Y URL)

Variable(s)	Tipo	Descripción
genres	JSON stringificado	Lista de géneros; se codifica con one-hot encoding.
production_companies, production_countries, spoken_languages	JSON stringificado	Metadatos de producción; se codifican con one-hot encoding.
belongs_to_collection	JSON stringificado	Se convierte en indicador binario es_franquicia .
title, original_title	Texto	Nombre comercial y nombre original; no se usan como predictores.
overview, tagline	Texto	Sinopsis y eslogan; excluidos del modelo final.
homepage, poster_path	URL	No relevantes para la predicción; descartadas.

Table IV
VARIABLES DERIVADAS POR TARGET ENCODING TEMPORAL

Variable	Tipo	Descripción
director_hist_avg	Numérica continua	Media histórica regularizada del target para el director, calculada con películas anteriores al estreno.
main_company_hist_avg	Numérica continua	Media histórica regularizada del target para la compañía productora principal.

production_companies y **production_countries** se parsean desde formato JSON y se codifican con *one-hot encoding*. La variable **original_language** agrupa idiomas poco frecuentes en *otros* antes de aplicar *one-hot encoding*. **status** se codifica con *one-hot encoding*. **adult** es binaria y no requiere transformación. **belongs_to_collection** se convierte en el indicador binario **es_franquicia**. Finalmente, **release_date** se descompone en mes, año y día de la semana; el mes se codifica además con transformación cíclica (**month_sin**, **month_cos**) para respetar su naturaleza periódica.

Paradigma de aprendizaje

El problema se formula como **regresión supervisada**, dado que la variable objetivo es continua y el conjunto de datos cuenta con etiquetas reales para todas las muestras. El target se define como $y = \log(\text{revenue}/\text{budget})$: el cociente normaliza la heterogeneidad temporal del período 1960–2017, y el logaritmo reduce la asimetría, que pasa de 2.96 en escala original a -0.87 tras la transformación. El objetivo es aprender una función

$f: \mathbf{x} \rightarrow \log(\text{revenue}/\text{budget})$, donde $\mathbf{x}$ contiene únicamente características disponibles antes del estreno. Las métricas de evaluación final se reportan en escala original de revenue (USD) mediante la transformación inversa $\widehat{\text{revenue}} = \exp(\hat{y}) \times \text{budget}$.

III. ESTADO DEL ARTE

Se realizó una búsqueda en IEEE Xplore, Elsevier, Springer y PubMed, identificando cuatro trabajos representativos sobre predicción de ingresos cinematográficos con aprendizaje de máquina.

Sharda y Delen [3] presentan uno de los trabajos fundacionales en este dominio. El problema se formula como *clasificación supervisada*, asignando cada película a una de nueve categorías de taquilla (de *flop* a *blockbuster*). La técnica empleada es una red neuronal multicapa (MLP) entrenada con siete variables pre-estreno: calificación MPAA, género, presencia de secuela, mes de lanzamiento, número de pantallas, valor estelar del reparto y efectos especiales. La validación se realizó con 10-fold cross-validation. Las métricas son la tasa de clasificación exacta (*bingo rate*) y la tasa de acierto dentro de una categoría adyacente (*1-away accuracy*), ambas propias del esquema ordinal adoptado. Los resultados fueron 36.9% y 75.2%, respectivamente, superando a regresión logística y análisis discriminante en el mismo conjunto de datos.

Velingkar et al. [4] abordan el problema bajo un paradigma de *regresión supervisada*, estimando directamente el ingreso numérico a partir de variables pre-estreno como género, presupuesto, popularidad esperada y compañía productora. La técnica seleccionada es Random Forest Regression. La validación se realizó mediante partición entrenamiento/prueba, y las métricas empleadas son el error cuadrático medio (RMSE) y el coeficiente de determinación (R^2). El trabajo no reporta valores numéricos precisos de desempeño, pero concluye que Random Forest supera a la regresión lineal, y extiende el modelo para recomendar valores óptimos de presupuesto y duración dado un ingreso objetivo.

Zhang, Meng y Xiao [5] proponen un enfoque híbrido que combina minería de texto con regresión supervisada. Se seleccionan 34 factores en 11 categorías —incluyendo índice de popularidad, tipo de película, fecha de estreno y taquilla del primer día— y se emplea Word2Vec para construir un tesoro de características, mientras que TF-IDF (*Term Frequency–Inverse Document Frequency*) calcula puntuaciones emocionales a partir de comentarios de usuarios. Sobre estas representaciones se entrena un modelo de Regresión Lineal Multivariada (MLR). La validación es k -fold cross-validation, y las métricas reportadas son MAE y RMSE. Cabe señalar que este trabajo incorpora la taquilla del primer día como predictor, lo que implica información post-estreno y distingue su configuración de la adoptada en el presente estudio.

Lu, Wang y Nguyen [6] aplican el paradigma de *clasificación supervisada* al mercado cinematográfico de Taiwán. Se emplea Random Forest para predecir el rango de ingreso final de una película, comparándolo contra SVM

y Regresión Logística. La métrica principal es la precisión global de clasificación (*overall accuracy*), definida como la fracción de instancias correctamente clasificadas sobre el total. El modelo Random Forest alcanzó un 80% de precisión global, el mayor entre los algoritmos evaluados. Adicionalmente, se aplica un método no supervisado para distinguir grupos dentro de las categorías de ingresos, y el análisis de importancia de características señala que el boca a boca (*word-of-mouth*) es el factor más determinante.

En conjunto, estos trabajos muestran que los ensambles de árboles superan consistentemente a los modelos lineales en este dominio. El presente estudio amplía el espacio de modelos evaluados —incluyendo SVM, redes neuronales y tres variantes de ensambles de árboles— y aplica técnicas de reducción de dimensión (PCA y UMAP) para analizar la estructura del espacio de características, operando sobre $y = \log(\text{revenue}/\text{budget})$ para normalizar la heterogeneidad temporal y corregir la asimetría de la variable objetivo.

IV. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

A. Configuración experimental

El conjunto de trabajo (4721 películas) se particiona de forma estratificada por quintil de `release_year` para garantizar cobertura temporal uniforme en cada subconjunto:

- **Train:** 3303 muestras (70%).
- **Validación:** 709 muestras (15%).
- **Test:** 709 muestras (15%).

La unión train+validación (85%) se emplea para el ajuste de hiperparámetros mediante `GridSearchCV` con 5-fold cross-validation estratificado por quintil temporal. El criterio interno de optimización es minimizar el RMSE en escala log-ratio (numéricamente estable). El conjunto de test permanece intocable hasta la evaluación final.

Métricas de desempeño: Las métricas de evaluación final se reportan en escala original de ingresos (USD), obtenida mediante la transformación inversa $\widehat{\text{revenue}} = \exp(\hat{y}) \times \text{budget}$:

- **RMSE (USD):** penaliza errores grandes en escala monetaria; sensible a outliers.
- **MAE (USD):** error absoluto medio; robusto a outliers y en la misma escala que la variable objetivo.
- R^2 : coeficiente de determinación; adimensional y comparable con la literatura.
- R^2 **ajustado:** penaliza la complejidad por el número de predictores ($p = 140$).
- **IC 95 % bootstrap** ($B = 1000$): sobre el conjunto de test; permite determinar si dos modelos son estadísticamente distinguibles.

La elección de estas métricas responde a las características del problema: RMSE se prioriza porque en decisiones de inversión cinematográfica los errores grandes (subestimar o sobreestimar por decenas de millones) tienen consecuencias desproporcionadas; MAE complementa al ofrecer una lectura robusta a valores extremos; R^2 y R^2 ajustado permiten comparar con la literatura existente y penalizar modelos




Figure 1. Efecto del hiperparámetro principal en el RMSE de CV para cada familia de modelos.

con exceso de variables; y el IC bootstrap proporciona significancia estadística sin supuestos distribucionales sobre los residuos.

Modelos comparados: Se evalúan 9 modelos agrupados en las 5 familias exigidas por la guía del curso. La Tabla V detalla cada modelo con su malla de hiperparámetros. En total se exploran 148 combinaciones hiperparamétricas.

B. Resultados del entrenamiento de modelos

Resultados de validación cruzada: La Tabla VI presenta el RMSE medio de CV (en escala log-ratio) con su intervalo de confianza al 95 % y los mejores hiperparámetros seleccionados para cada modelo.

Los intervalos de confianza de GBR, HGB, los tres modelos lineales y Random Forest se solapan ampliamente, indicando que sus diferencias en CV no son estadísticamente significativas. SVR, MLP y KNN quedan por debajo de este grupo.

Efecto de los hiperparámetros: La Fig. 1 muestra las curvas de CV RMSE en función del hiperparámetro principal de cada familia, con barras de error correspondientes a la desviación estándar entre los 5 folds. En general, los modelos lineales (Ridge, LASSO, ElasticNet) son insensibles a la regularización mientras esta sea baja y se degradan con valores altos de α ; KNN mejora al aumentar k ; los ensambles de árboles presentan curvas relativamente planas en todo el rango explorado; SVR con $\gamma = \text{scale}$ obtiene su mínimo en $C = 1$ y se degrada al aumentar C ; y MLP favorece la arquitectura más amplia (128, 64).

Evaluación final en train, validación y test: La Tabla VII presenta las métricas finales en escala USD sobre los tres subconjuntos. El IC 95 % se calcula por bootstrap ($B = 1000$) sobre test.

Análisis del trade-off sesgo-varianza: El gap entre RMSE en train y RMSE en test refleja el trade-off sesgo-varianza. Los modelos lineales regularizados (Ridge, LASSO, ElasticNet) presentan mayor sesgo pero menor varianza: su RMSE en train es alto (≈ 120 M USD) y el gap con test es pequeño (≈ 9 M). Los ensambles de árboles tienen menor sesgo (RMSE train entre 64.5 y 89.7 M) y mayor varianza (gap entre 12 y 35 M). El caso de KNN con weights=distance ($k = 40$) es extremo: el RMSE en train cae a 92 USD y el de test sube a 116.6 M, lo que corresponde a memorización del conjunto de entrenamiento por la ponderación inversa a la distancia. La variante diagnóstica KNN_uniform_k20 confirma este efecto: con weights=uniform y $k = 20$ fijos el gap se reduce a aproximadamente 5.6 M, indicando que el problema proviene de la combinación weights=distance con alta dimensionalidad y no del algoritmo en sí.

Random Forest obtiene el menor RMSE en test (99.9 M USD) y el mayor R^2 ajustado (0.53), seguido por HGB y GBR (101.7 M, R^2 ajustado 0.52). Los intervalos de confianza al 95 % sobre test se solapan ampliamente entre todos los modelos: por ejemplo, el IC de Random Forest [82.6 M, 117.0 M] se solapa con el de HGB [85.1 M, 118.5 M] y con el de Ridge [92.6 M, 128.2 M]. En consecuencia, las diferencias en test no son estadísticamente significativas bajo este criterio.

La Fig. 2 muestra las tres métricas en test con su IC 95 %, confirmando visualmente el solapamiento de intervalos descrito arriba.

La Fig. 3 compara los tres subconjuntos por modelo en escala logarítmica, donde se observa que la mayoría de los modelos presenta barras de magnitud comparable (orden de 10^8) en train, validación y test. La excepción es KNN con weights=distance, cuyo comportamiento ya se describió arriba.

Los resultados aquí presentados corresponden a la ronda baseline con el conjunto completo de $p = 140$ predictores. La Sección V retoma este protocolo sobre el conjunto reducido por análisis individual y filtros de redundancia.

V. REDUCCIÓN DE DIMENSIÓN

A. Análisis individual de variables

Sobre el conjunto de 140 predictores se calculan tres índices complementarios: correlación de Pearson (linealidad), correlación de Spearman (monotonía) e información mutua (dependencias no lineales). La Fig. 4 muestra el top-20 según |Pearson| y según información mutua.

Las variables con mayor información mutua son `franchise_x_runtime` (0.078), `budget_x_collection` (0.077), `log_budget_x_franchise` (0.075), `collection_size` (0.071), `es_franquicia` (0.061), `budget_x_n_genres` (0.053) y `cast_size` (0.052). Variables con MI alto pero Pearson bajo (por ejemplo `budget_x_n_genres`, $r = 0.022$, MI= 0.053) reflejan relaciones no lineales que el filtro lineal no captura.

Identificación de candidatos a eliminar: Se aplica un filtro conservador combinando los tres índices: una variable es candidata a eliminación si cumple simultáneamente

Table V
MODELOS EVALUADOS Y MALLAS DE HIPERPARÁMETROS

Familia	Modelo	Hiperparámetros explorados
Paramétrico (reg. regularizada L2)	Ridge	$\alpha \in \{0.001, 0.01, 0.1, 1, 10, 100, 1000\}$
Paramétrico (selección embebida L1)	LASSO	$\alpha \in \{0.0001, 0.001, 0.01, 0.1, 1.0\}$
Paramétrico (mezcla L1+L2)	ElasticNet	$\alpha \in \{0.001, 0.01, 0.1, 1\}$; $l_1_ratio \in \{0.05, 0.2, 0.5, 0.8, 0.95\}$
No paramétrico	KNN	$k \in \{5, 10, 20, 40\}$; $weights \in \{uniform, distance\}$
Ensamble de árboles	Random Forest	$n_est \in \{300, 600\}$; $max_depth \in \{None, 15, 25\}$; $min_samples_leaf \in \{1, 3, 5\}$; $max_features \in \{0.5, sqrt\}$
Ensamble de árboles (boosting)	GBR	$n_est \in \{300, 600\}$; $max_depth \in \{3, 5, 7\}$; $learning_rate \in \{0.03, 0.05, 0.1\}$
Ensamble de árboles (boosting moderno)	HGB	$learning_rate \in \{0.05, 0.1\}$; $max_depth \in \{None, 6, 10\}$; $min_samples_leaf \in \{20, 50\}$; $max_iter \in \{300, 600\}$
SVM	SVR (RBF)	$C \in \{1, 10, 50\}$; $\gamma \in \{scale, 0.01, 0.1\}$; $\varepsilon \in \{0.05, 0.1\}$
Red neuronal	MLP	$hidden \in \{(64), (128, 64), (64, 32, 16)\}$; $\alpha \in \{10^{-4}, 10^{-3}\}$; $lr_init \in \{10^{-3}, 10^{-2}\}$

Table VI
RESULTADOS DE GRIDSEARCHCV (5-FOLD, ESCALA LOG-RATIO). IC 95 % CALCULADO SOBRE LOS 5 FOLDS.

Modelo	RMSE_CV	IC 95 %	Mejores hiperparámetros
GBR	1.1641 ± 0.0162	[1.1499, 1.1783]	$lr=0.05$, $max_depth=3$, $n_est=600$
HGB	1.1657 ± 0.0169	[1.1509, 1.1805]	$lr=0.1$, $max_depth=None$, $min_leaf=50$, $max_iter=300$
LASSO	1.1698 ± 0.0145	[1.1570, 1.1825]	$\alpha=0.001$
Ridge	1.1699 ± 0.0143	[1.1573, 1.1825]	$\alpha=1.0$
ElasticNet	1.1698 ± 0.0146	[1.1570, 1.1826]	$\alpha=0.001$, $l_1_ratio=0.95$
RandomForest	1.1704 ± 0.0135	[1.1586, 1.1822]	$max_depth=25$, $max_feat=0.5$, $min_leaf=3$, $n_est=300$
SVR	1.1854 ± 0.0224	[1.1658, 1.2051]	$C=1$, $\varepsilon=0.1$, $\gamma=scale$
MLP	1.2021 ± 0.0283	[1.1773, 1.2269]	$hidden=(128,64)$, $\alpha=10^{-4}$, $lr=0.01$
KNN	1.2481 ± 0.0173	[1.2329, 1.2632]	$k=40$, $weights=distance$

Table VII
EVALUACIÓN FINAL EN ESCALA USD (REVENUE). MODELOS ORDENADOS POR RMSE EN TEST. KNN CORRESPONDE AL GANADOR DEL GRIDSEARCHCV (WEIGHTS=DISTANCE, $k=40$); KNN_UNIFORM_K20 ES LA VARIANTE DIAGNÓSTICA CON WEIGHTS=UNIFORM, $k=20$ FIJOS.

Modelo	RMSE train	RMSE val	RMSE test	IC 95 % lo	IC 95 % hi	MAE test	R^2 adj
	(millones USD, salvo indicación)						
RandomForest	64.5	63.7	99.9	82.6	117.0	48.9	0.53
HGB	86.6	80.7	101.7	85.1	118.5	51.0	0.52
GBR	89.7	86.5	101.7	85.1	117.6	51.2	0.52
SVR	65.9	52.9	108.5	86.0	128.0	52.3	0.45
ElasticNet	120.5	118.1	111.0	92.2	128.2	53.5	0.43
LASSO	120.5	118.2	111.0	92.2	128.3	53.5	0.43
Ridge	120.3	115.9	111.1	92.6	128.2	53.3	0.42
MLP	102.2	94.3	111.8	91.3	132.8	55.4	0.42
KNN_uniform_k20	108.2	119.9	113.8	94.3	132.9	55.8	0.40
KNN	\$92.1	\$80.2	116.6	96.3	135.8	55.8	0.37

$|\text{Pearson}| < 0.03$, $|\text{Spearman}| < 0.03$ y $MI < 0.007$. Bajo este criterio quedan 61 candidatas a eliminar de las 140 totales.

Validación con Sequential Forward Selection: Para contrastar el filtro estadístico contra una selección guiada por modelo, se aplica SFS con Ridge ($\alpha = 10$)

sobre las 30 variables con mayor MI, configurado para seleccionar 12. Las variables elegidas son `franchise_x_runtime`, `log_budget_x_franchise`, `es_franquicia`, `budget_x_n_genres`, `cast_size`, `main_company_hist_avg`, `crew_size`, `keywords_count`, `has_homepage`, `n_genres`, `kw_independent_film` y




Figure 2. Métricas en test (RMSE, MAE, R^2) por modelo, con barras de error correspondientes al IC 95 % bootstrap ($B = 1000$).




Figure 3. Comparación de RMSE en train, validación y test por modelo (escala logarítmica, USD).

g_Comedy.

Decisión sobre las variables candidatas: Se valida la eliminación de las 61 candidatas comparando el RMSE de CV con Ridge sobre el conjunto completo y sobre el conjunto reducido:

- Conjunto completo (140 feats): RMSE = 1.1718 ± 0.0150 , IC 95 % = [1.1586, 1.1849].
- Conjunto reducido (79 feats): RMSE = 1.1765 ± 0.0129 , IC 95 % = [1.1651, 1.1878].

Los IC 95 % se solapan, por lo que la diferencia no es estadísticamente significativa y se procede a eliminar las 61 variables.

Filtro de redundancia entre predictores: Sobre las 79 variables sobrevivientes se calcula la matriz de correlación absoluta entre predictores. Para cada par con $|r| > 0.95$ se conserva la variable más correlacionada con el target y se elimina la otra. Se encontraron 10 pares y se eliminaron 8 variables: `budget_x_collection`, `director_hist_avg`, `es_franquicia`, `kw_sequel`, `log_budget_x_franchise`, `log_budget_x_year`, `n_genres` y `top3_actors_hist_avg`. El conjunto queda en 71 predictores con RMSE de CV = 1.1912 ± 0.0155 , IC 95 % = [1.1776, 1.2047].

Selección embebida agresiva con LASSO: Para reducir aún más el conjunto se aplica un barrido del *regularization path* de LASSO. Para cada valor de α se cuentan los coeficientes activos y se evalúa el RMSE de CV usando Ridge como evaluador neutral, comparando contra el IC 95 % del conjunto pre-selección (71 feats). La Fig. 5 ilustra

Table VIII
REGULARIZATION PATH DE LASSO. RMSE EVALUADO CON RIDGE SOBRE EL SUBSET ACTIVO. LA COLUMNA “SOLAPA” INDICA SI EL IC 95 % DEL SUBSET SE SOLAPA CON EL DEL CONJUNTO PRE-SELECCIÓN DE 71 FEATS.

α	#activas	RMSE_CV	IC lo	IC hi	solapa
0.0001	70	1.1912	1.1776	1.2047	sí
0.0002	69	1.1907	1.1774	1.2039	sí
0.0005	68	1.1906	1.1773	1.2039	sí
0.0012	67	1.1905	1.1772	1.2038	sí
0.0028	64	1.1898	1.1761	1.2034	sí
0.0066	59	1.1885	1.1746	1.2024	sí
0.0152	51	1.1917	1.1773	1.2060	sí
0.0351	35	1.1912	1.1749	1.2074	sí
0.0811	12	1.2125	1.2004	1.2246	sí
0.1874	4	1.2464	1.2247	1.2681	no

el trade-off complejidad-error.

Se selecciona $\alpha = 0.0351$, que activa 35 variables y mantiene el solape de IC 95 % con el conjunto pre-selección. Tras aplicar la reducción, las matrices quedan con 34 columnas: $\mathbf{X}_{trainval}$ de forma (4012, 34), $\mathbf{X}_{test}$ de forma (709, 34). La reducción respecto al conjunto pre-selección de 71 predictores es del 50.7 %.

Reentrenamiento sobre el conjunto reducido: Se ejecuta nuevamente el protocolo de la Sección IV sobre el conjunto de 34 predictores. Los dos mejores modelos según RMSE en test son **SVR** (RMSE = 98.6 M USD) y **HGB** (RMSE = 99.9 M USD). Estos son los modelos sobre los que se aplican PCA y UMAP en las subsecciones siguientes.

B. Extracción de características lineal: PCA

Se aplica PCA sobre el conjunto reducido de 34 predictores estandarizados (**StandardScaler** ajustado en train+val). La Fig. 6 muestra la curva de varianza explicada acumulada con los umbrales de 75 % y 90 % superpuestos.

Para cada umbral se obtiene:

- 75 % de varianza: 20 componentes (reducción 41.2 %).
- 90 % de varianza: 27 componentes (reducción 20.6 %).




Figure 4. Top 20 variables por |Pearson| (izquierda) y por información mutua (derecha) frente al target $\log(\text{revenue}/\text{budget})$.




Figure 5. Regularization path de LASSO: número de variables activas y RMSE de CV (Ridge sobre el subset activo) en función de α . La banda verde marca el rango objetivo de 30-40 variables; la línea discontinua representa el RMSE pre-selección con 71 feats.




Figure 6. PCA: varianza explicada acumulada en función del número de componentes. Líneas discontinuas en 75 % y 90 %.

Se evalúan ambos umbrales con los dos mejores modelos (SVR y HGB) reentrenados con sus mejores hiperparámetros. La Tabla IX resume los resultados.

Se adopta el umbral del 90 % para las comparaciones siguientes: con 75 % la reducción es mayor pero el desempeño se degrada, mientras que con 90 % el desempeño es estadísticamente equivalente al del conjunto sin reducción.

C. Extracción de características no lineal: UMAP

Se aplica UMAP sobre los mismos datos estandarizados con un barrido de $n_components \in \{5, 10, 20, 40\}$. Como

Table IX
COMPARACIÓN DE UMBRALES PCA (75 % Y 90 %) SOBRE LOS DOS MEJORES MODELOS. RMSE EN USD; IC 95 % BOOTSTRAP ($B = 1000$).

Config.	#comp	RMSE (M)	IC 95 %	R^2
75% / SVR	20	98.91	[82.88, 117.29]	0.63
75% / HGB	20	106.92	[88.57, 125.87]	0.57
90% / SVR	27	98.29	[82.75, 115.65]	0.64
90% / HGB	27	102.72	[86.35, 119.59]	0.61

Table X
BARRIDO UMAP: RMSE Y R^2 EN TEST (USD) PARA CADA DIMENSIÓN.

Modelo	d	Reducción	RMSE test (M USD)	R^2 test
SVR	5	85.3 %	119.25	0.4685
SVR	10	70.6 %	115.58	0.5007
SVR	20	41.2 %	115.83	0.4985
HGB	5	85.3 %	118.64	0.4740
HGB	10	70.6 %	115.53	0.5011
HGB	20	41.2 %	119.59	0.4655

Table XI
MEJOR CONFIGURACIÓN UMAP POR MODELO CON IC 95 % BOOTSTRAP ($B = 1000$).

Modelo	d	RMSE test (M USD)	IC 95 %	R^2
HGB	10	115.53	[94.80, 135.37]	0.50
SVR	10	115.58	[94.23, 136.35]	0.50

el conjunto reducido tiene 34 predictores, la dimensión 40 se descarta porque $d \geq p$ no representa reducción. Las dimensiones evaluadas son $\{5, 10, 20\}$. La configuración utilizada es $n_neighbors=30$ y $min_dist=0.1$.

La Tabla X reporta el barrido completo y la Tabla XI la mejor dimensión por modelo con su IC 95 % bootstrap.

La mejor dimensión para ambos modelos es $d = 10$




Figure 7. Comparación del RMSE en test (USD) para SVR y HGB en tres configuraciones: conjunto original (34 feats), PCA con 90 % de varianza (27 feats) y UMAP óptimo (10 feats).

Table XII
COMPARATIVA FINAL: ORIGINAL VS PCA VS UMAP. RMSE E IC 95 % EN MILLONES DE USD.

	Original (34 feats)	PCA (27 feats)	UMAP (10 feats)
SVR	98.6 [82.0, 117.3]	98.3 [82.8, 115.6]	115.6 [94.2, 136.4]
HGB	99.9 [83.7, 116.9]	102.7 [86.4, 119.6]	115.5 [94.8, 135.4]

(reducción del 70.6 %), pero el RMSE en test crece a ≈ 115.5 M USD, significativamente mayor que el del conjunto sin reducción.

D. Comparativa: original vs PCA vs UMAP

La Fig. 7 y la Tabla XII resumen el efecto de las dos técnicas de reducción sobre los dos mejores modelos.

VI. DISCUSIÓN Y CONCLUSIONES

El modelo con menor RMSE en test sobre el conjunto reducido de 34 predictores es SVR (98.6 M USD), seguido por HGB (99.9 M USD). En términos interpretables, el modelo ganador presenta un error multiplicativo mediano de $1.96\times$ — es decir, la predicción típica difiere del valor real por un factor menor a 2 — y una mediana de revenue predicho de \$35.5 M frente a \$38.2 M reales.

PCA con 27 componentes (90 % de varianza explicada) reduce el número de variables en 20.6 % manteniendo un RMSE prácticamente idéntico al del conjunto original (SVR: 98.29 vs 98.63 M USD; HGB: 102.72 vs 99.92 M USD). Los IC 95 % se solapan ampliamente entre las dos configuraciones, lo que indica que la reducción es estadísticamente equivalente al conjunto sin reducción.

UMAP, por el contrario, alcanza una reducción mucho mayor (70.6 % con $d = 10$) pero el RMSE crece a ≈ 115.5 M USD para ambos modelos. El comportamiento es coherente con la naturaleza del método: UMAP es un algoritmo de *manifold learning* cuyo uso natural es la visualización en baja dimensión, no la regresión.

La selección de características por filtro (Pearson, Spearman, MI) y por wrapper (SFS) coinciden en gran medida sobre el subconjunto más relevante; LASSO confirma esta selección vía regularización embebida, reduciendo de 140 a 34 predictores sin degradación estadísticamente significativa del RMSE.

Limitaciones

El modelo opera exclusivamente sobre metadatos pre-estreno disponibles en TMDb. Variables como el gasto en marketing, la estrategia de distribución, el momento cultural y el boca a boca — factores que la literatura identifica como determinantes — no están presentes en el dataset y constituyen ruido irreducible. El MAPE de 240 % refleja esta limitación: aunque la mediana de las predicciones es razonable, los errores en películas con ingresos extremos son proporcionalmente grandes.

Comparación con el estado del arte

Los resultados obtenidos se enmarcan dentro del rango reportado en la literatura revisada (Sección III). Velingkar et al. [4] concluyen que Random Forest supera a los modelos lineales en este dominio, hallazgo consistente con los resultados del baseline de este trabajo (Sección IV), donde Random Forest, HGB y GBR ocupan las tres primeras posiciones en RMSE sobre el conjunto de 140 predictores. Sobre el conjunto reducido a 34 variables, los dos mejores modelos pasan a ser SVR y HGB. Lu et al. [6] identifican el boca a boca como factor más determinante en su configuración de clasificación; en el presente estudio, basado exclusivamente en metadatos pre-estreno, las variables con mayor información mutua corresponden a interacciones de franquicia y presupuesto (`franchise_x_runtime`, `budget_x_collection`, `log_budget_x_franchise`), señalando la pertenencia a una colección como predictor relevante. Sharda y Delen [3] y Zhang et al. [5] trabajan bajo formulaciones distintas (clasificación ordinal de nueve clases y regresión con minería de texto, respectivamente) y sus métricas no son directamente comparables con el RMSE en USD reportado aquí.

REFERENCES

- [1] Gower Street Analytics, “Box office revenue in North America, China, and worldwide from 2017 to 2023,” Statista, Jan. 2024. [En línea]. Disponible en: <https://www.statista.com/statistics/1419672/box-office-revenue-china-world-north-america/>
- [2] R. Banik, “The Movies Dataset,” Kaggle, 2017. [En línea]. Disponible en: <https://www.kaggle.com/datasets/rounakbanik/the-movies-dataset>
- [3] R. Sharda and D. Delen, “Predicting box-office success of motion pictures with neural networks,” *Expert Systems with Applications*, vol. 30, no. 2, pp. 243–254, 2006.
- [4] G. Velingkar, R. Varadarajan, S. Lanka, and A. Kumar M, “Movie box-office success prediction using machine learning,” in *Proc. 2nd Int. Conf. Power, Control and Computing Technologies (ICPC2T)*, 2022, pp. 1–6.
- [5] Z. Zhang, Y. Meng, and D. Xiao, “Prediction techniques of movie box office using neural networks and emotional mining,” *Scientific Reports*, vol. 14, p. 21209, Sep. 2024. doi: <https://doi.org/10.1038/s41598-024-72340-z>
- [6] S.-H. Lu, H.-J. Wang, and A. T. Nguyen, “Machine learning applications on box-office revenue forecasting: The Taiwanese film market case study,” in *Optimal Transport Statistics for Economics and Related Topics*, ser. Studies in Systems, Decision and Control, vol. 483. Springer, 2023, pp. 384–402. doi: https://doi.org/10.1007/978-3-031-35763-3_49