

Comparación de Modelos de Aprendizaje de Máquina en la Predicción de Ingresos Cinematográficos

Brahiam Acosta Bedoya, Kevin Estrada Del Valle, Juan Andrés Rivera Arango

Abstract—Este trabajo aborda la predicción de ingresos en taquilla cinematográfica mediante técnicas de aprendizaje de máquina, usando exclusivamente metadatos disponibles antes del estreno de cada película. A partir de *The Movies Dataset*, que contiene información histórica de 45 466 títulos, se construye un conjunto de trabajo de 5 197 películas con presupuesto e ingresos reportados. El problema se formula como regresión supervisada sobre la transformación logarítmica del ingreso, justificada por la alta asimetría de la variable original.

Index Terms—Aprendizaje de máquina, regresión supervisada, predicción de ingresos, taquilla cinematográfica, análisis de datos.

I. INTRODUCCIÓN

La industria cinematográfica es uno de los mercados de entretenimiento más grandes del mundo, con ingresos globales en taquilla que superaron los 42 mil millones de dólares antes de la pandemia [1]. En este entorno, el éxito comercial de una película es difícil de anticipar: títulos con presupuestos millonarios han fracasado en taquilla, mientras que producciones modestas han superado todas las expectativas. Esta incertidumbre representa un problema real de toma de decisiones para productoras, distribuidoras e inversionistas.

Históricamente, estas decisiones han dependido del juicio experto y de comparaciones informales con títulos similares. Sin embargo, la disponibilidad de bases de datos estructuradas con metadatos de miles de películas abre la posibilidad de construir modelos cuantitativos que aprendan patrones a partir de los datos. Aquí es donde el aprendizaje de máquina ofrece una contribución concreta: a diferencia de los modelos estadísticos clásicos, los algoritmos de ML pueden capturar relaciones no lineales entre variables heterogéneas —numéricas, categóricas y estructuradas— sin requerir supuestos fuertes sobre la forma de la distribución subyacente.

Este trabajo propone aplicar técnicas de regresión supervisada para estimar el ingreso en taquilla de una película antes de su estreno, usando únicamente información disponible en esa etapa. Se comparan múltiples modelos —desde regresión lineal hasta ensambles de árboles y redes neuronales— con el objetivo de identificar cuál captura mejor la relación entre los metadatos disponibles y el desempeño comercial.

II. DESCRIPCIÓN DEL PROBLEMA

Contexto

Estimar el ingreso en taquilla de una película antes de su estreno es un problema de predicción con alto valor práctico. Las decisiones de inversión en la industria cinematográfica —presupuesto de marketing, número de salas, ventana de lanzamiento— se toman semanas o meses antes del estreno, cuando la única información disponible son los metadatos del proyecto: presupuesto de producción, género, idioma, fecha de lanzamiento y popularidad del título, entre otros.

Construir un modelo que relacione estas características con el ingreso esperado permite cuantificar la incertidumbre y apoyar decisiones basadas en evidencia. El problema es adecuado para un enfoque de ML porque involucra múltiples variables de distinto tipo, relaciones potencialmente no lineales entre ellas, y un volumen de datos suficiente para entrenar y validar modelos de forma robusta.

Base de datos

Se emplea *The Movies Dataset* [2], construido a partir de TMDb y GroupLens. El archivo principal, `movies_metadata.csv`, contiene 45 466 registros y 24 variables. Tras excluir filas con IDs malformados, eliminar 30 duplicados, y filtrar los registros con `budget=0` o `revenue=0` —que representan datos no reportados y no ausencias reales— y restringir el período a 1960–2017, el conjunto de trabajo queda en **5 197 películas**. Las tablas I, II y III describen las variables disponibles.

Las variables numéricas clave muestran correlaciones de Pearson con $\log(\text{revenue})$ de $r = 0.70$ para $\log(\text{budget})$ y $r = 0.66$ para $\log(\text{vote_count})$, lo que confirma la capacidad predictiva de los predictores seleccionados.

Calidad de datos y preprocesamiento

El 80.4 % de los registros originales tienen `budget=0` y el 83.7 % tienen `revenue=0`; en ambos casos se trata de datos no reportados, no de valores reales, por lo que se excluyen del conjunto de entrenamiento. La variable `runtime` presenta 263 nulos (0.58 %), imputados con la mediana; las variables `status` y `original_language` tienen menos del 0.2 % de nulos, imputados con la categoría *Desconocido*.

En cuanto a la codificación: `genres`, `production_companies` y `production_countries` se parsean desde formato JSON y se codifican con *one-hot encoding*. La variable `original_language` agrupa idiomas poco frecuentes en *otros* antes de aplicar *one-hot encoding*; el 88.9 % de las películas del conjunto limpio están en inglés.

Table I
VARIABLES NUMÉRICAS PRINCIPALES

Variable	Tipo	Descripción
budget	Numérica continua	Presupuesto de producción en USD.
revenue	Numérica continua	Variable objetivo: ingresos en taquilla en USD.
popularity	Numérica continua	Índice de popularidad calculado por TMDB.
runtime	Numérica continua	Duración de la película en minutos.
vote_average	Numérica continua	Calificación promedio (1–10).
vote_count	Numérica entera	Número de votos recibidos.

Table II
VARIABLES CATEGÓRICAS Y TEMPORALES

Variable	Tipo	Descripción
release_date	Fecha	Se descompone en mes, año y día de la semana.
original_language	Categórica nominal	Idioma original; idiomas con menos de 20 apariciones se agrupan en <i>otros</i> .
status	Categórica nominal	Estado de producción (Released, Rumored, etc.).
adult	Binaria	Indicador de contenido para adultos (0/1).

Table III
VARIABLES ESPECIALES (JSON, TEXTO Y URL)

Variable(s)	Tipo	Descripción
genres	JSON stringificado	Lista de géneros; se codifica con one-hot encoding.
production_companies, production_countries, spoken_languages	JSON stringificado	Metadatos de producción; se codifican con one-hot encoding.
belongs_to_collection	JSON stringificado	Se convierte en indicador binario es_franquicia .
title, original_title	Texto	Nombre comercial y nombre original; no se usan como predictores.
overview, tagline	Texto	Sinopsis y eslogan; excluidos del modelo final.
homepage, poster_path	URL	No relevantes para la predicción; descartadas.

status se codifica con *one-hot encoding*. **adult** es binaria y no requiere transformación. **belongs_to_collection** se convierte en el indicador binario **es_franquicia**: el 23.3%

de las películas pertenecen a una franquicia y su revenue mediano (\$97M) es aproximadamente cuatro veces mayor al de las películas independientes (\$23M). Finalmente, **release_date** se descompone en mes, año y día de la semana.

Paradigma de aprendizaje

El problema se formula como **regresión supervisada**, dado que la variable objetivo $\log(\text{revenue} + 1)$ es continua y el conjunto de datos cuenta con etiquetas reales para todas las muestras. Se aplica la transformación $\log(\text{revenue} + 1)$ porque el ingreso original presenta una asimetría de 4.43, que se reduce a -0.13 tras la transformación, estabilizando la varianza y favoreciendo el entrenamiento. El objetivo es aprender una función $f: \mathbf{x} \rightarrow \log(\text{revenue} + 1)$, donde $\mathbf{x}$ contiene únicamente características disponibles antes del estreno.

III. ESTADO DEL ARTE

Se realizó una búsqueda en IEEE Xplore, Elsevier, Springer y PubMed, identificando cuatro trabajos representativos sobre predicción de ingresos cinematográficos con aprendizaje de máquina.

Sharda y Delen [3] presentan uno de los trabajos fundacionales en este dominio. El problema se formula como *clasificación supervisada*, asignando cada película a una de nueve categorías de taquilla (de *flop* a *blockbuster*). La técnica empleada es una red neuronal multicapa (MLP) entrenada con siete variables pre-estreno: calificación MPAA, género, presencia de secuela, mes de lanzamiento, número de pantallas, valor estelar del reparto y efectos especiales. La validación se realizó con 10-fold cross-validation. Las métricas son la tasa de clasificación exacta (*bingo rate*) y la tasa de acierto dentro de una categoría adyacente (*1-away accuracy*), ambas propias del esquema ordinal adoptado. Los resultados fueron 36.9% y 75.2%, respectivamente, superando a regresión logística y análisis discriminante en el mismo conjunto de datos.

Velingkar et al. [4] abordan el problema bajo un paradigma de *regresión supervisada*, estimando directamente el ingreso numérico a partir de variables pre-estreno como género, presupuesto, popularidad esperada y compañía productora. La técnica seleccionada es Random Forest Regression. La validación se realizó mediante partición entrenamiento/prueba, y las métricas empleadas son el error cuadrático medio (RMSE) y el coeficiente de determinación (R^2).

El trabajo no reporta valores numéricos precisos de desempeño, pero concluye que Random Forest supera a la regresión lineal, y extiende el modelo para recomendar valores óptimos de presupuesto y duración dado un ingreso objetivo.

Zhang, Meng y Xiao [5] proponen un enfoque híbrido que combina minería de texto con regresión supervisada. Se seleccionan 34 factores en 11 categorías —incluyendo índice de popularidad, tipo de película, fecha de estreno y taquilla del primer día— y se emplea Word2Vec para construir un

tesauro de características, mientras que TF-IDF calcula puntuaciones emocionales a partir de comentarios de usuarios. Sobre estas representaciones se entrena un modelo de Regresión Lineal Multivariada (MLR). La validación es k -fold cross-validation, y las métricas reportadas son MAE y RMSE, donde el MAE se define como:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|. \quad (1)$$

A diferencia del RMSE, el MAE pondera todos los errores por igual sin penalizar de forma desproporcionada los valores atípicos. Cabe señalar que este trabajo incorpora la taquilla del primer día como predictor, lo que implica información post-estreno y distingue su configuración de la adoptada en el presente estudio.

Lu, Wang y Nguyen [6] aplican el paradigma de *clasificación supervisada* al mercado cinematográfico de Taiwán. Se emplea Random Forest para predecir el rango de ingreso final de una película, comparándolo contra SVM y Regresión Logística. La métrica principal es la precisión global de clasificación (*overall accuracy*), definida como la fracción de instancias correctamente clasificadas sobre el total. El modelo Random Forest alcanzó un 80% de precisión global, el mayor entre los algoritmos evaluados. Adicionalmente, se aplica un método no supervisado para distinguir grupos dentro de las categorías de ingresos, y el análisis de importancia de características señala que el boca a boca (*word-of-mouth*) es el factor más determinante.

En conjunto, estos trabajos muestran que la regresión supervisada sobre metadatos pre-estreno produce resultados consistentes. El presente estudio amplía el espacio de modelos evaluados —incluyendo SVM, redes neuronales y ensambles de árboles— y aplica técnicas de reducción de dimensión (PCA y UMAP) para analizar la estructura del espacio de características, operando sobre la transformación $\log(\text{revenue}+1)$ para corregir la alta asimetría de la variable objetivo.

REFERENCES

- [1] Gower Street Analytics, “Box office revenue in North America, China, and worldwide from 2017 to 2023,” Statista, Jan. 2024. [En línea]. Disponible en: <https://www.statista.com/statistics/1419672/box-office-revenue-china-world-north-america/>
- [2] R. Banik, “The Movies Dataset,” Kaggle, 2017. [En línea]. Disponible en: <https://www.kaggle.com/datasets/rounakbanik/the-movies-dataset>
- [3] R. Sharda and D. Delen, “Predicting box-office success of motion pictures with neural networks,” *Expert Systems with Applications*, vol. 30, no. 2, pp. 243–254, 2006.
- [4] G. Velingkar, R. Varadarajan, S. Lanka, and A. Kumar M, “Movie box-office success prediction using machine learning,” in *Proc. 2nd Int. Conf. Power, Control and Computing Technologies (ICPC2T)*, 2022, pp. 1–6.
- [5] Z. Zhang, Y. Meng, and D. Xiao, “Prediction techniques of movie box office using neural networks and emotional mining,” *Scientific Reports*, vol. 14, p. 21209, Sep. 2024. doi: <https://doi.org/10.1038/s41598-024-72340-z>
- [6] S.-H. Lu, H.-J. Wang, and A. T. Nguyen, “Machine learning applications on box-office revenue forecasting: The Taiwanese film market case study,” in *Optimal Transport Statistics for Economics and Related Topics*, ser. Studies in Systems, Decision and Control, vol. 483. Springer, 2023, pp. 384–402. doi: https://doi.org/10.1007/978-3-031-35763-3_49